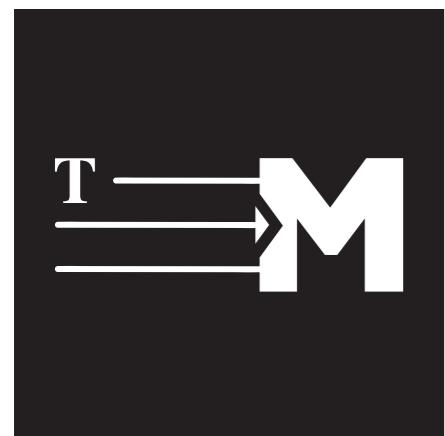


08 T2M - text to map

T2M è un applicativo che, tramite modelli di intelligenza artificiale, sintetizza un testo in parole chiave.

Al termine viene visualizzata una mappa di parole che, disposte in base all'importanza, restituiscono in sintesi il senso generale del discorso, dando infine la possibilità all'utente di affinare il risultato ottenuto con correzioni.



#Word2Vec
#p5.speech
#mind-map
#entity-detection
#synthesis

github.com/dsii-2020-unirsm
github.com/Gregorio-V

Gregorio Vaccari

a destra
Dal contenuto testuale al relativo schema concettuale in pochi secondi.

from text:

...Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Nunc sed augue lacus viverra orci. Sit amet est placeat in egestas erat. Ut tellus eleme ntum sagittis vitae. Vene nata tellus in metus vulputate eu scelerisque felis imperdiet proin. Nibh tortor id aliquet lectus proin nibh nisl condimentum id. Nibh praesent tristique magna sit amet purus gravida. Dicti met vestibulum rhoncus est pellentesque et ultricies dignissim oras. At varius vel phaedra vel turpis nunc eget eodem dolor. Potenti nullam ab tortor vitae purus faucibus oras.

Donec adipiscing tristique risus nec feugiat in fermentum posuere urna. Aliquet nec ullamcorper sit amet nisl nullam. Tortor posuere ac ut consequat sem per viverra nam libero. Sed felis eget velit aliquet sagittis. Lacus laoreet non curabitur gravida arcu ac. Etiam dignissim diam quis enim lobortis scelerisque fermentum du. Laoreet sit amet cursus sit amet arcu non sodales neque sodales ut etiam sit. Lacus sed viverra tellus in hac habuisse platea. Sit amet nisl nullam eget felis eget nunc loboris. Amet vivamus cursus eget nunc scelerisque viverra mauris. Molestie at elementum eu facilisis. Amet risus nisl nullam eget felis eget nunc loboris mattis. At volutpat diam ut venenatis tellus in metus vulputate. Enim nulla aliquet porttitor lacus luctus accumsan tortor posuere. Nam libero justus laoreet sit amet cursus sit quis hendrerit dolor magna eget et lorem ipsum dolor. Elit dui tristique sollicitudin nibh sit amet commodo. Volutpat sed oras ornare arcu du vivamus arcu felis. Odio tempor orci dapibus vitiosus in arcu lis nunc sed.

Enim lobortis scelerisque fermentum du facilisis in. Enim nec du nunc mattis enim ut. Molestie nunc non blandit massa enim nec du. Pretium lectus quam id leo in vivitur turpis massa sed tellus in hac habuisse platea. Etiquia ullamcorper malesuada proin libero nunc consequat interdum varius. Cras ornare arcu du vivamus arcu felis bibendum ut. Libero volutpat sed oras ornare arcu du vivamus. ullamcorper sit amet nisl nullam eget felis eget nunc. Interdum posuere lorem ipsum dolor sit amet pellentesque eu tincidunt ut tortor aliquam nulla. Molestie a iaculis at et rat pellentesque adipiscing commodo elit at. Lacus sed viverra tellus in ornare quam viverra orci sagittis eu volutpat odio facilisis mauris. Risus pretium quam vulputate dignissim suspendisse in est ante in. Nec vivitur suscipit tellus mauris a. Nibh venenatis oras sed felis eget velit blandit volutpat maecenas volutpat blandit aliquam. Egestas diam in arcu cursus. Non curabitur gravida arcu ac. Sit amet nulla facilisi morbi tempus. Phasellus egestas tellus nisl in tellus pellentesque. Lectus nulla at volutpat diam. Dolor sit amet consectetur adipiscing elit dui tristique sollicitudin. Turpis in eu mi bibendum neque egestas congue quisque. Sit amet justo donec enim diam vulputate ut pharetra sit. Dui nunc...

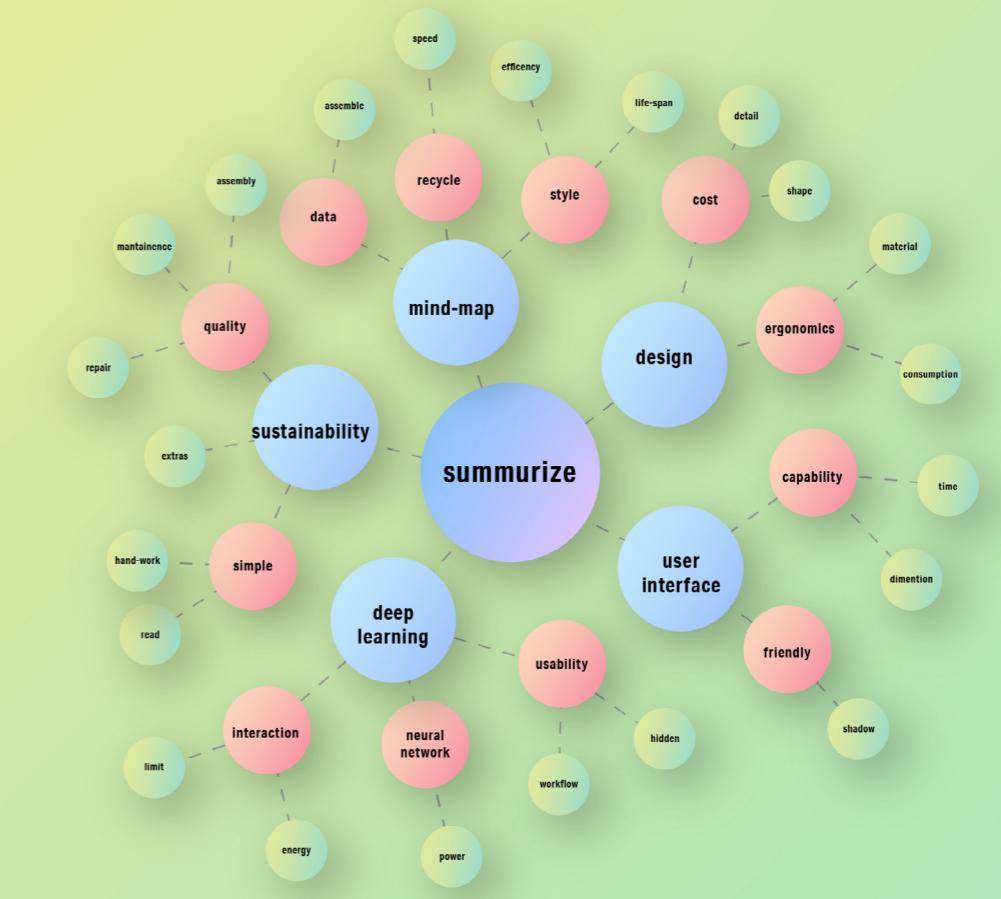
...amet consectetur. Elementum te ipsum egestas sed sed neus pretium quam vulputate dignissim.

Ut venenatis tellus in metus vulputate. Velle eros donec ac odio tempor orci dapibus. Arcu du vivamus arcu felis bibendum. Quisque non tellus orci ac auctor augue. Sit amet venenatis urna cursus. Sit amet nisl suscipit adipiscing bibendum est ultricies integer quis. Eget aliquet nibh praesent tristique magna. Purus faucibus ornare suspendisse sed nisl lacus sed. Sed viverra ipsu in nunc aliquet. Risus viverra adipiscing at tellus integer feugiat scelerisque. Malesuada fames ac turpis egestas maecenas pharetra convallis posuere morbi. Urna porttitor rhoncus dolor purus non enim. Purus in massa tempor nec. In fermentum posuere urna nec tincidunt praesent semper feugiat nibh. Sit amet consectetur adipiscing elit dui tristique. Nec du nunc mattis enim ut tellus elementum sagittis. Diam volutpat commodo sed egestas egestas fringilla. Tellus in mauris a diam maecenas sed enim ut tellus in viverra. sed felis eget velit aliquet sagittis id consectetur. Orcia scelerisque purus semper eget dui at tellus.

Adipiscing vitae proin sagittis nisl rhoncus mattis rhoncus urna. Et leo dui ut diam quam nulla porttitor. Felis eget velit aliquet sagittis id. Feugiat pretium nibh ipsum consequat nisl vel. Egestas tellus nisl in tellus pellentesque eu tincidunt ut tortor aliquam nulla. Molestie a iaculis at et rat pellentesque adipiscing commodo elit at. Lacus sed viverra tellus in ornare quam viverra orci sagittis eu volutpat odio facilisis mauris. Risus pretium quam vulputate dignissim suspendisse in est ante in. Nec vivitur suscipit tellus mauris a. Nibh venenatis oras sed felis eget velit blandit volutpat maecenas volutpat blandit aliquam. Egestas diam in arcu cursus. Non curabitur gravida arcu ac. Sit amet nulla facilisi morbi tempus. Phasellus egestas tellus nisl in tellus pellentesque. Lectus nulla at volutpat diam. Dolor sit amet consectetur adipiscing elit dui tristique sollicitudin. Turpis in eu mi bibendum neque egestas congue quisque.

Sit amet justo donec enim diam vulputate ut pharetra sit. Dui nunc...

to map:



L'origine

Il progetto nasce da un approfondimento sulla tecnologia di *word embedding*, un metodo di trasformazione delle parole in vettori grazie al *machine learning*. Il risultato di questa operazione è un elenco di parole, nello specifico quelle contenute nel database con cui è stata allenata la macchina, ognuna collegata ad un vettore, ovvero una sequenza di numeri che identificano un punto in uno spazio 3D. Grazie a questa trasformazione è possibile svolgere operazioni matematiche tra i vettori, e di conseguenza con le parole. Da tale approfondimento è nata una ricerca su contesti d'uso potenzialmente adatti a questa tecnologia in ambito didattico/testuale/umanistico. Una prima ipotesi consisteva in uno strumento che assistesse il singolo o un team nella generazione di idee, attraverso la fruizione di una "mappa" di parole chiave correlate semanticamente tra loro. È tuttavia risultato problematico un inserimento agile e una fruizione scorrevole del prodotto all'interno di un *workflow* che si suppone libero e tendenzialmente privo di strumenti diversi dalla scrittura e da semplici annotazioni, rendendo così l'idea inutilizzabile. Per questo motivo si è fatto un passo indietro, cercando di individuare ciò che effettivamente possa risultare utile durante o dopo una discussione, facilitando il compito o svolgendo in automatico parte della procedura.

La ricerca

Si è quindi scelto di non limitare il contesto d'uso all'ambito esclusivamente lavorativo, bensì di estendere la ricerca al più generale campo di analisi di dialoghi o discussioni. Il *focus* del progetto si è rivolto verso uno strumento che prevede un'interazione con l'utente non più durante, ma al termine del processo, evitando così il problema riscontrato nella prima sperimentazione. Tra le varie opzioni è sembrato interessante approfondire software e altri strumenti in grado di agevolare la sintesi testuale, processo laborioso ma che si rivela sempre più fondamentale. Compiere la sintesi di un testo presuppone una comprensione approfondita del suo significato, la capacità di individuare i nodi concettuali chiave, stabilire gerarchie di im-

in alto a sinistra
GEKO (progetto precedente) prevedeva l'interazione con la macchina e la visualizzazione ad ologramma.

in alto a destra
Lista delle abbreviazioni usate nella classificazione dei metodi per il processo di sintesi testuale.

(fonte: <https://medium.com/@meetkumar/machine-learning-approach-for-automatic-text-summarization-using-neural-networks-fe6238860826>)

in basso
Sezione API Demo di Summerizebot con varie tipologie di analisi del testo, tra cui il riassunto e l'identificazione di parole chiave.



Abbreviations	Meaning
TF	Term Frequency
IF-IDF	Term Frequency-inverse document frequency
POK	Position of a Keyword
HMM	Hidden Markov Model
DT	Decision Trees
ME	Maximum Entropy
NN	Neural Networks
NB	Naïve Bayes
DLCSS	Direct lexical chain span score
DLCS	Direct lexical chain score
LCSS	Lexical chain span score
LCS	Lexical chain score
RST	Rhetorical Structure Theory
LC	Lexical chain
GPR	Google's Pagerank
HITS	Hyperlinked Induced Topic Search
MLSA	Meta Latent Semantic Analysis
SNMF	Symmetric nonnegative matrix factorization
SLSS	Sentence level semantic analysis
LSA	Latent Semantic Analysis
NMF	Non-Negative Matrix factorization
SVD	Singular Value Decomposition
SDD	Semi-Discrete Decomposition

The image shows a computer monitor displaying the Summerizebot API Demo interface. The interface has a header with the logo and navigation links: API for Business, Products, Technology, Pricing, Demo, Documentation, Contacts, and Try API for Free. Below the header, there's a section titled "Text Analysis API Demo" with a sub-section "Summarization". A text input field contains the URL "https://www.reuters.com/article/us-tesla-musk-sec/tesla-musk-mocks-sec-as-judge-demands-they-justify-fraud-settlement-idUSKCN1ME2CC" and a dropdown menu set to "Summary Size: 20%". To the right of the input field is a "Summarize" button. Below the input field, there's a "Keywords and key phrases" section listing terms like "federal appeal court, security fraud settlement, exchange commission, chief executive, ominous sign, denial, vast majority, regular practice, southern district, electric car company". Underneath this, there's an "AI-powered summary" section with a block of text about Elon Musk and the SEC. At the bottom of the monitor, the Apple logo is visible.

portanza tra i concetti e riprodurre in forma sintetica una versione che mantenga lo stesso senso globale del testo di partenza; questa può essere elaborata nuovamente in forma testuale oppure sotto forma di schema. Ad oggi esistono diversi strumenti in grado di riassumere con senso ogni tipo di testo; uno di questi è SummerizeBot, il quale può essere aggiunto anche a gruppi Slack e permette di effettuare svariate tipologie di analisi di testo: non solo la sintesi testuale, ma anche *keyword* o *keyphrases*, ovvero operazioni che permettono di individuare parole o concetti chiave.

GPT-3

GPT-3. Uno studente del college ha utilizzato GPT-3 (*language-generating AI tool*) con lo scopo di produrre un post di un blog completamente creato da una macchina; il fatto interessante è che questo post è arrivato ad essere il primo articolo su Hacker News.

L'articolo ha il titolo: “*Feeling unproductive? Maybe you should stop overthinking.*”. Non solo l'articolo non è stato riconosciuto come prodotto da un computer, ma è risultato anche estremamente facile crearlo.

GPT-3 è la versione aggiornata del GPT-2, entrambi i modelli sono stati allenati per la generazione di testo ma la nuova versione è estremamente più performante della prima, come dimostrano i risultati raggiunti con la scrittura dell'articolo sopra citato. Questo caso appare significativo del grado di sviluppo raggiunto dall'intelligenza artificiale negli ultimi anni e della sua effettiva usabilità in ambito commerciale.

Semantris

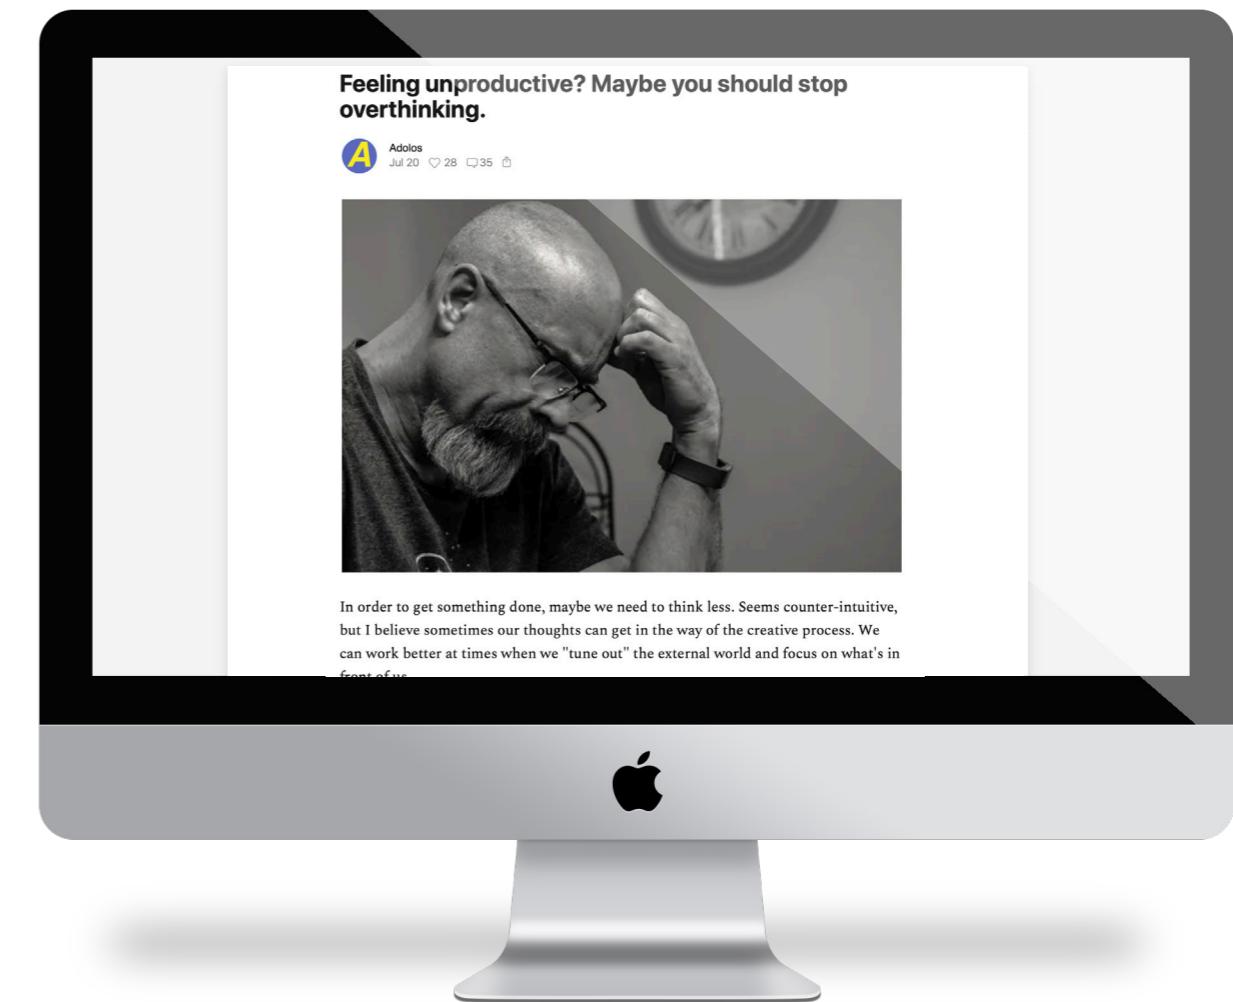
Semantris utilizza tecnologie di *machine learning* per la comprensione del linguaggio, nello specifico per le associazioni tra parole. Tale sistema viene utilizzato per la creazione di due videogiochi; ogni volta che si inserisce una parola, il programma cerca quale tra le parole in gioco presenta una relazione maggiore con quella inserita dall'utente. La capacità di associazione sfruttata in questi videogiochi si avvicina per funzionamento al comando di Word2Vec, il quale ricerca la parola più vicina semanticamente a

in alto
Screenshot dell'articolo “*Feeling unproductive? Maybe you should stop overthinking*” creato da un'intelligenza artificiale.

(Screenshot da: <https://adolos.substack.com/p/feeling-unproductive-maybe-you-should>)

in basso
Screenshot dal sito del progetto Semantris con i due differenti giochi.

(Screenshot da: <https://research.google.com/semantris/>)



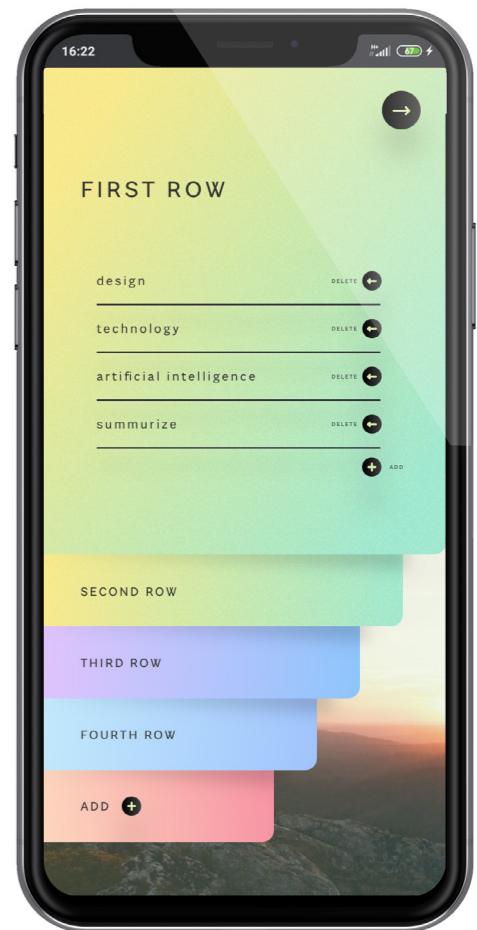
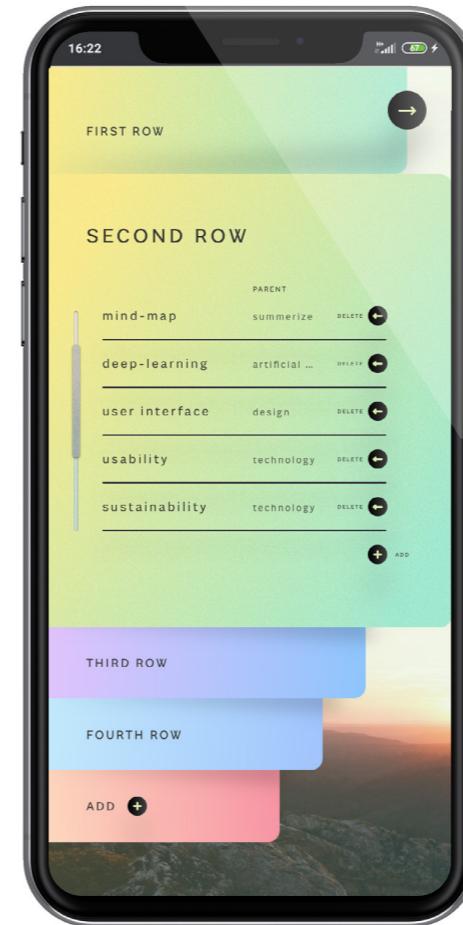
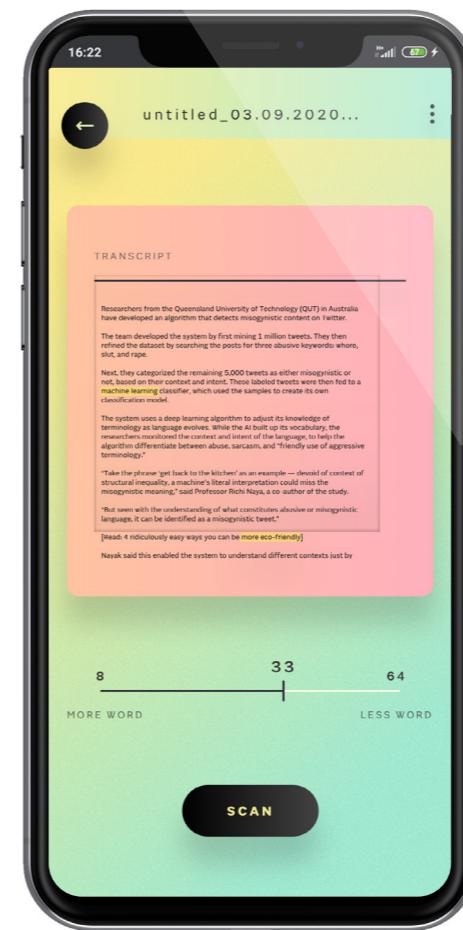
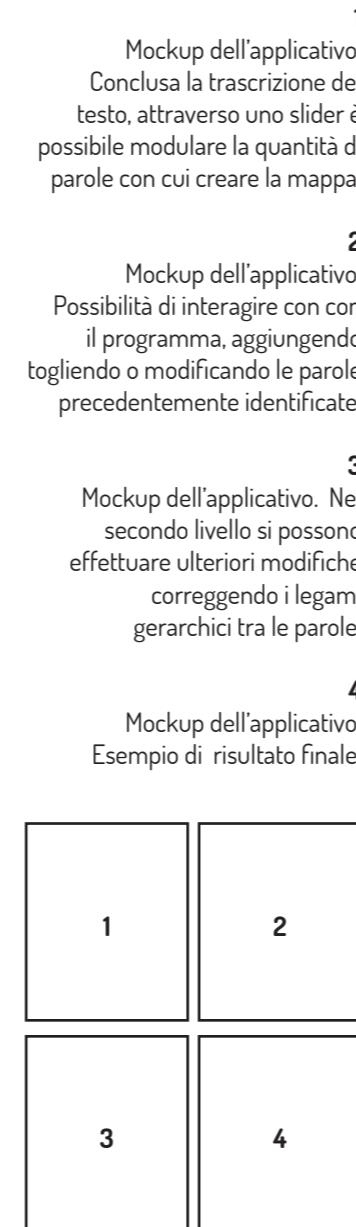
quella richiesta. Il gioco come espediente narrativo dell'esperimento permette di esplorare la "mente" della macchina, per accorgersi della stupefacente somiglianza tra i collegamenti che compie la mente umana e quelli effettuati dall'intelligenza artificiale.

Cos'è

T2M è un software che permette la trasformazione di un dialogo o di un testo scritto in una mappa concettuale recante le parole semanticamente più importanti del discorso. Questo strumento è pensato per sintetizzare discorsi, idee o concetti “*on the spot*”, nell’immediato, per evitare che vadano perse intuizioni o suggestioni. Un’interfaccia permette di variare le parole chiave selezionate dall’intelligenza artificiale nel caso fosse necessaria una mappa più accurata. Date le limitazioni della macchina, il risultato non sarà paragonabile ad un accurato lavoro svolto da un essere umano, d’altra parte questo strumento ambisce ad inserirsi nella fetta di mercato in cui non è richiesta accuratezza, ma velocità. Tuttavia, tale sistema fornirebbe all’utente l’indubbio vantaggio di risparmiare tempo, generando una sorta di schizzo che, per quanto approssimativo, risulterebbe comunque portatore del senso generale del discorso, in grado di estrapolarne e fissarne i concetti chiave. In un secondo momento, se necessario, l’utente potrà affinare e perfezionare il risultato ottenuto. Un elemento importante del software è l’elaborazione della mappa utilizzando la tecnologia Word2Vec per compiere operazioni con gli elementi del discorso. Sarà infatti possibile visualizzare varie mappe: una semplice, formata dalle parole ricavate dal testo e in aggiunta, in base alle esigenze, mappe che presentano funzionalità diverse, proponendo sinonimi, concetti affini oppure parole di significato opposto rispetto a quelle iniziali. Queste molteplici potenziali elaborazioni possono rappresentare stimoli ulteriori allo sviluppo del discorso.

Cosa significa

Lo scopo di questo progetto è soprattutto quello di fare luce sulle possibilità nel campo della sintesi di testi da parte di intelligenze artificiali, finora poco utilizzate

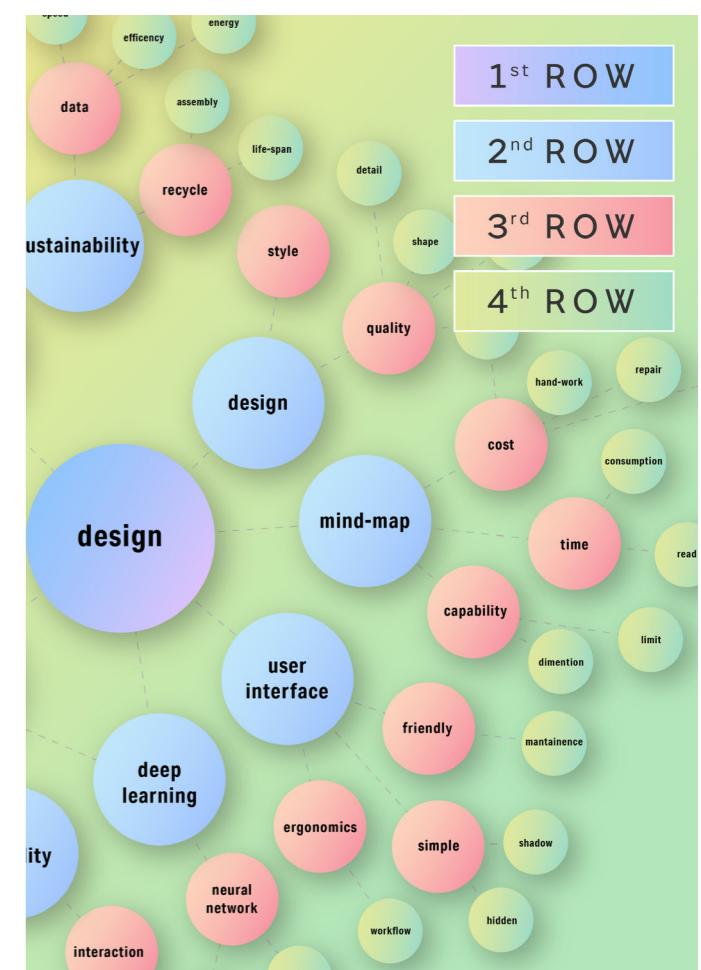
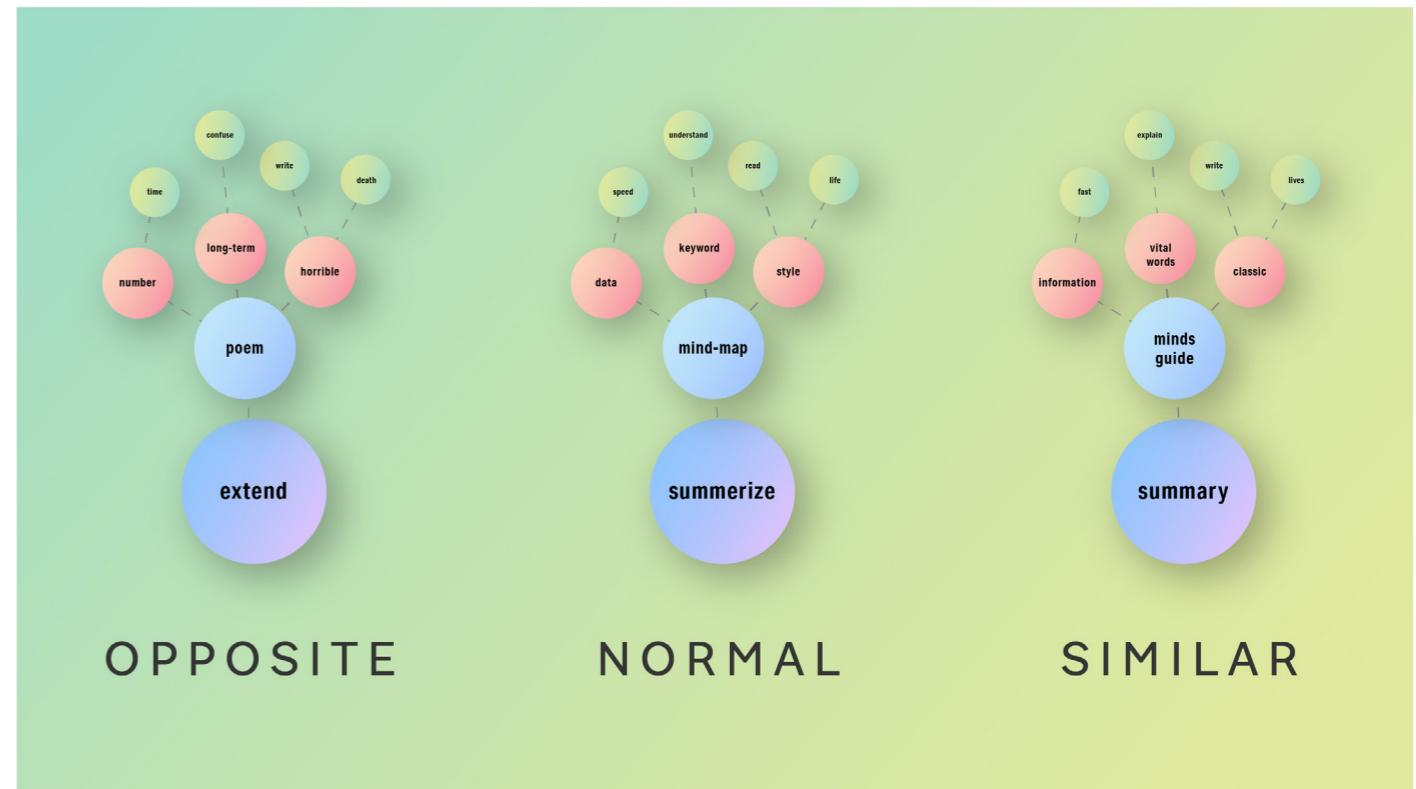
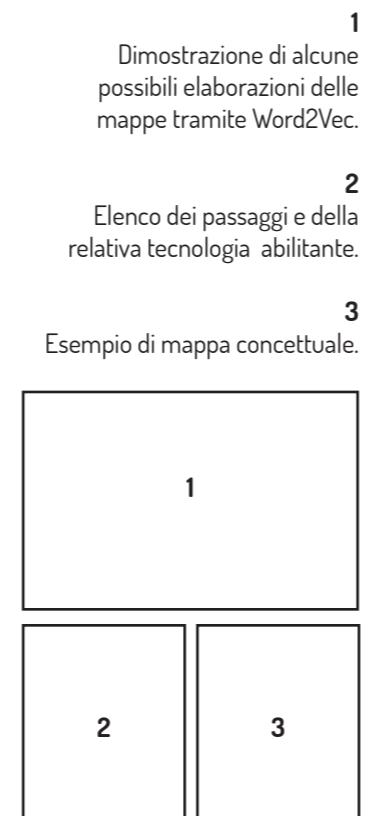


in questo ambito. Ancora non sono comuni risultati utilizzabili a livello professionale, ma le nuove macchine e le grosse capacità di calcolo fanno ben sperare sui prossimi sviluppi dei software, sempre più capaci di trattare e sintetizzare grosse moli di informazioni. Nello specifico, T2M ambisce a diventare strumento utile a professionisti di qualsiasi campo, a studenti o a persone comuni, a chiunque necessiti di tenere traccia del “succo” generale di un discorso, ascoltato o letto. Si pensi a conferenze stampa, assemblee, riunioni di lavoro, lezioni universitarie e ogni altro contesto in cui viene veicolato un contenuto complesso di cui interessa mantenere traccia solamente a grandi linee. In questi casi, T2M può venire in aiuto nella generazione automatica di uno schema che riporti il senso complessivo, sintetizzato in parole chiave e collegamenti base tra i concetti. Questa tecnologia non vuole diventare un sostituto dell'intelletto umano, piuttosto deve essere considerata come strumento che viene utilizzato dall'uomo e che necessita dell'intervento umano per un perfezionamento.

Funzionamento

Avviando la registrazione, il programma inizia a trascrivere il flusso vocale, trasformando le parole pronunciate in testo attraverso p5.speech o altri algoritmi simili.

Successivamente, il testo viene elaborato da Dandelion entity-detection, che identifica e classifica elementi chiave del discorso in categorie predefinite. Questa libreria permette di modulare il numero di parole estratte, permettendo così di scegliere quanto ampia risulterà la mappa. Un'ulteriore elaborazione del testo serve a suddividere le parole in base agli ambiti semanticci e successivamente organizzarle per importanza. Questo passaggio può essere compiuto contando il numero di ripetizioni di ogni parola chiave o, in alternativa, attraverso altri modelli capaci di identificare l'importanza della parola. A questo punto un'interfaccia permetterà di aggiungere, togliere parole dall'elenco oppure modificarne il livello di importanza. Concluso questo passaggio, il software fornirà una mappa concettuale formata dalle parole



disposte gerarchicamente in base all'importanza e all'ambito semantico; esse saranno posizionate più o meno centralmente e si presenteranno in dimensioni proporzionali al grado di rilevanza predeterminato.

Criticità

Elementi di criticità si rintracciano nell'identificazione delle parole chiave del discorso da parte del software e nella successiva attribuzione di importanza alle stesse. La soluzione di utilizzare come criterio di scelta la ripetizione della singola parola può essere significativa, ma passibile di generare risultati con un certo grado di imprecisione. Altri criteri più raffinati che ricorrono a ulteriori modelli allenati appositamente per lo scopo sono in via di perfezionamento. Inoltre, il progetto è sviluppato utilizzando algoritmi indipendenti tra loro, perché non creati specificamente per questo scopo, quindi non pensati per entrare in sinergia.

Scenari futuri

Credo che la necessità di svolgere sintesi di informazioni risulterà sempre più impellente nel prossimo futuro, vista la tendenza della popolazione italiana e non solo a ridurre il grado di approfondimento delle informazioni, come rilevato dall'indagine OCSE-PI-AAC conclusasi nel 2015, con tutte le problematiche a questo collegate. Un comune cittadino che desideri informarsi sullo stato socio-politico-culturale di un paese accede a informazioni che sono inevitabilmente filtrate dalla soggettività della fonte che le veicola, sia essa un giornale, un TG, un blog, un personaggio politico o un semplice conoscente. Durante questo passaggio la realtà assume sfaccettature diverse, subendo modificazioni, se non distorsioni. L'utilizzo di una macchina può risolvere questo problema, generando una sintesi di informazioni che sia il più oggettiva e imparziale possibile, regolabile a vari livelli di profondità. Sarebbe interessante sviluppare uno strumento che permetta la fruizione accelerata di varie fonti di informazione, analizzando diverse testate e vari argomenti in breve tempo, anche grazie all'utilizzo di immagini, mappe, audio, frasi o parole chiave, il tutto personalizzabile dall'utente.

in alto

Prototipo1. Attraverso
p5.speech viene registrata
la voce e trascritto il testo.
Utilizzando entity-detection di
Dandelion vengono selezionate
le parole chiave; una parte
del codice elenca in ordine
alfabetico le parole e controlla
non ci siano ripetizioni.

in basso

Prototipo2. Il testo viene preinserito dall'utente per iscritto. In seguito, il programma compie gli stessi passaggi sopracitati e propone una visualizzazione gerarchica delle parole chiave. Nello specifico, le parole ripetute due volte appaiono al centro, le restanti ai margini del cerchio.

p5* File ▾ Edit ▾ Sketch ▾ Help ▾

Auto-refresh p5-speech+entity_noVisual by Gregg-lash

sketch.js Saved: 3 minutes ago

```
25
26  function stopRec(){
27    mousePressed(myRec.stop());
28  }
29
30  function showResult() {
31    let text = myRec.resultString;
32    key_extractor(text)
33  }
34
35 }
36
37
38  function key_extractor(testo) {
39
40    console.log("Testo registrato:" + testo)
41
42    loadJSON('https://api.dandelion.eu/datatxt/nex/v1/?lang=en&text=' + testo +
43      '&include=types%2Cabstract%2Ccategories%2Clog&include=image&min_confidence=0,4&token=5db5cba74eb741bba4068e13c
44      54c917b', gotData);
45
46  function gotData(datatxt) {
47
48    for (let i = 0; i < datatxt.annotations.length; i++) {
49      let keyword = datatxt.annotations[i].spot;
50      keywords.push(keyword)
51      reps.push(1)
52    }
53    sorter(keywords)
54  }
55 }
```

Console Clear ▾

```
Testo registrato:if you're doing strength training to increase your fitness get stronger an  
d improve your health the most important thing is to do something  
Entità identificate: fitness,health,strength training  
Numero di ripetizioni: 1,1,1
```

p5*

File ▾ Edit ▾ Sketch ▾ Help ▾

Auto-refresh prova_entity+visual_mappaa by Gregg-lash

sketch.js* Saved: about 16 hours ago

```
3
4 let testo = 'As a fitness columnist, I get lots of questions about the best way to work
out. Many of these queries are about strength training: How many workouts per week are
necessary? Do I need to lift weights, or are body weight exercises like pushups and lunges
enough? Is it better to do a few repetitions of heavy weights or more reps with lighter
ones? How many sets are optimal? The reality is: Unless you're a bodybuilder or training
for powerlifting, those details aren't all that important. If you're doing strength
training to increase your fitness, get stronger, and improve your health, "The most
important thing is to just do something," says Greg Nuckols, founder of
StrongerByScience.com and a powerlifter who's held three world records. "The number one
principle is to start doing it and continue doing it – that's probably where of the health
benefits come from."'
5
6 let keywords = []
7 let reps = []
8 let parole = []
9
10 function setup() {
11   createCanvas(w, h);
12   textAlign(CENTER);
13   textSize(20);
14   key_extractor(testo)
15 }
16
17 function draw() {
18   background(220);
19   mostra_parole(parole)
20 }
21
22 }
23
24
25
26 function mostra_parole(keywords) {
27 }
```

Preview

Console

Clear ▾

Entità identificate: body weight, bodybuilder, exercises, fitness, health, health benefits, lunges, powerlifter, powerlifting, pushups, repetitions, strength training, work out, workouts

Numero di ripetizioni: 1,1,1,2,1,1,1,1,1,1,1,2,1,1

Sitografia

- <https://learn.ml5js.org/docs/#/reference/word2vec>
- <https://idmnyu.github.io/p5.js-speech/>
- <https://gist.github.com/aparrish/2f562e3737544cf29aaf1af30362f469>
- <https://github.com/anvaka/word2vec-graph>
- <https://projector.tensorflow.org>
- <https://towardsdatascience.com/learn-word2vec-by-implementing-it-in-tensorflow-45641adaf2ac>
- http://www.generative-gestaltung.de/1/M_6_4_01_TOOL
- <https://research.google.com/semantris/>
- <https://www.summarizebot.com>
- <https://dandelion.eu>
- <https://github.com/ml5js/ml5-library/issues/141>
- <https://medium.com/luisfredgs/automatic-text-summarization-with-machine-learning-an-overview-68ded5717a25>

Prototipi

- <https://editor.p5js.org/Gregg-lash/sketches/EU1G-me0T>
(con testo scritto + visual)
- <https://editor.p5js.org/Gregg-lash/sketches/T1b3uA2CG>
(con p5.speech, solo console)
- <https://editor.p5js.org/Gregorio-V/sketches/XWDDgpzVH>
(possibile mappa 3d)